

Solución de sistemas lineales

PhD. Alejandro Paredes

Facultad de Ciencias

24 de abril de 2023

Resumen

- 1 Métodos directos e iterativos
- 2 Métodos iterativos
 - Método de Jacobi
 - Método Gauss-Seidel
 - SOR
- 3 Métodos de optimización
 - Método de máximo descenso
 - Método de gradiente conjugado
- 4 Sistemas mal condicionados.

Métodos directos e iterativos

Según las características del problema

- ▶ Tipo de matriz (triangular, tridiagonal, llena de ceros, sin ceros, etc)
- ▶ Tamaño del problema (dimensión de la matriz).
- ▶ Condicionamiento de la matriz.

Existen dos métodos (camino) para encontrar la solución

- ▶ Métodos directos (Sustitución directa e inversa, eliminación de Gauss con y sin pivote).
- ▶ Métodos iterativos (Jacobi, Gauss-Seidel, SOR, método del gradiente).

Nota: En ningún caso se calcula A^{-1}

Métodos iterativos $\mathcal{O}(n^2)$

- ▶ Adaptados para sistemas de gran dimensión.
- ▶ Calcula soluciones aproximadas.

Sistema lineal a resolver:

Solución : $[-1 \quad 3 \quad 2]$

$$\begin{bmatrix} 4 & 2 & 3 \\ 3 & -5 & 2 \\ -2 & 3 & 8 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 8 \\ -14 \\ 27 \end{bmatrix}$$

$$\begin{bmatrix} 4 & 2 & 3 \\ 3 & -5 & 2 \\ -2 & 3 & 8 \end{bmatrix} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & -5 & 0 \\ 0 & 0 & 8 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 \\ 3 & 0 & 0 \\ -2 & 3 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 2 & 3 \\ 0 & 0 & 2 \\ 0 & 0 & 0 \end{bmatrix}$$

Método de Jacobi

Si no hay ceros en la diagonal principal, entonces:

$$\begin{aligned}x &= (8 - 2y - 3z)/4 \\y &= (-14 - 3x - 2z)/(-5) \\z &= (27 + 2x - 3y)/8\end{aligned}$$

Los nuevos valores de x,y,z se obtienen a partir de los antiguos

$$\begin{aligned}x^{k+1} &= (8 - 2y^k - 3z^k)/4 \\y^{k+1} &= (-14 - 3x^k - 2z^k)/(-5) \\z^{k+1} &= (27 + 2x^k - 3y^k)/8\end{aligned}$$

con $(x^0, y^0, z^0) = (0, 0, 0)$

Método de Jacobi

$$\mathbf{D}\mathbf{x}^{k+1} = \mathbf{b} - (\mathbf{L} + \mathbf{U})\mathbf{x}^k$$

Forma compacta:

$$\mathbf{x}^{k+1} = \mathbf{D}^{-1} [\mathbf{b} - (\mathbf{L} + \mathbf{U})\mathbf{x}^k]$$

Formula de recurrencia:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{i \neq j} a_{ij} x_j^{(k)} \right)$$

Método Gauss-Seidel

A partir del método de Jacobi

$$\begin{aligned}x^{k+1} &= (8 - 2y^k - 3z^k)4 \\y^{k+1} &= (-14 - 3x^k - 2z^k)/(-5) \\z^{k+1} &= (27 + 2x^k - 3y^k)/8\end{aligned}$$

se actualizan los valores que ya se conocen

$$\begin{aligned}x^{k+1} &= (8 - 2y^k - 3z^k)4 \\y^{k+1} &= (-14 - 3x^{k+1} - 2z^k)/(-5) \\z^{k+1} &= (27 + 2x^{k+1} - 3y^{k+1})/8\end{aligned}$$

es más eficiente.

Método Gauss-Seidel-Forma compacta

El método de Gauss-Seidel se puede expresar de la siguiente manera:

$$(\mathbf{D} + \mathbf{L})\mathbf{x}^{k+1} = \mathbf{b} - \mathbf{U}\mathbf{x}^k$$

Forma compacta:

$$\mathbf{x}^{k+1} = (\mathbf{D} + \mathbf{L})^{-1} [\mathbf{b} - \mathbf{U}\mathbf{x}^k]$$

Formula de recurrencia:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=i+1}^n a_{ij}x_j^{(k)} - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} \right)$$

Sucesive Over Relaxation (SOR)

Descomposición de **A** :

$$[\mathbf{D} + \omega \mathbf{L} + (1 - \omega) \mathbf{L} + \mathbf{U}] \mathbf{x}^{k+1} = \mathbf{b}$$

Forma compacta:

$$[\mathbf{D} + \omega \mathbf{L}] \mathbf{x}^{k+1} = \mathbf{b} - [(1 - \omega) \mathbf{L} + \mathbf{U}] \mathbf{x}^k$$

Formula de recurrencia

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - (1 - \omega) \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} - \omega \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} \right)$$

Métodos iterativos estacionarios

A partir del sistema original $\mathbf{x} = G\mathbf{x} + c$, se propone el método iterativo de la forma

$$\mathbf{x}_{k+1} = G\mathbf{x}_k + c$$

por lo tanto tenemos

- ▶ Jacobi: $G = -D^{-1}(L + U)$
- ▶ Gauss-Seidel: $G = -(D + L)^{-1}U$
- ▶ SOR $G = -[\mathbf{D} + \omega\mathbf{L}]^{-1}[(1 - \omega)\mathbf{L} + \mathbf{U}]$

Error en la n -ésima aproximación es $\mathbf{e}^n = \mathbf{x} - \mathbf{x}^n$

$$\mathbf{e}^{n+1} = G\mathbf{e}^n$$

$$\mathbf{e}^n = G\mathbf{e}^{n-1} = G^2\mathbf{e}^{n-2} = \dots = G^n\mathbf{e}^0$$

La secuencia de soluciones $\{\mathbf{x}_1, \mathbf{x}_2, \dots\}$ converge cuando

$$\lim_{n \rightarrow \infty} \mathbf{e}^n = \lim_{n \rightarrow \infty} G^n \mathbf{e}^0 = \mathbf{0} \quad \Rightarrow \quad \boxed{\lim_{n \rightarrow \infty} G^n = \mathbf{0}}$$

Métodos iterativos estacionarios

Si $\dim(G)$ es m , suponemos que G tiene m autovectores independientes $\mathbf{v}_s (s = 1, \dots, m)$ y λ_s autovalores. Los \mathbf{v}_s forman una base y

$$\mathbf{e}^0 = \sum_{s=1, m} d_s \mathbf{v}_s$$

Además

$$\mathbf{e}^1 = \sum_{s=1, m} d_s G \mathbf{v}_s = \sum_{s=1, m} d_s \lambda_s \mathbf{v}_s \quad \Rightarrow \quad \boxed{\mathbf{e}^n = \sum_{s=1, m} d_s \lambda_s^n \mathbf{v}_s}$$

para un \mathbf{e}^0 arbitrario, \mathbf{e}^n tenderá a un vector nulo si y sólo si $|\lambda_s| < 1 \quad \forall s$.

El proceso convergerá para un \mathbf{x}^0 arbitrario si el radio espectral $\rho(G) < 1$

Método de optimización

Consideraremos

$$\Phi(x) = \frac{1}{2}x^T Ax - x^T b$$

donde $b, x \in R^n$ y $A \in R^{nn}$ es simétrica positiva definida (SPD)

Nota: SPD equivale a decir $x^T Ax > 0 \quad \forall x$ o los autovalores de A son positivos.

Sea x^* el valor que minimiza $\Phi(x)$

$$\nabla \Phi(x^*) = Ax^* - b = 0 \quad \Rightarrow \quad Ax^* = b$$

Resolver el sistema lineal se ha convertido en un problema de optimización

Método de máximo descenso

Planteamos que la solución se busca de manera iterativa:

$$x_{k+1} = x_k + \alpha_k p_k; \quad p_k : \text{vector}, \quad \alpha_k : \text{escalar}$$

se escoge una solución inicial x_0 tal que $\Phi(x_{k+1}) < \Phi(x_k)$.

Sabemos que:

- ▶ $\nabla\Phi(x)$: vector con dirección de máximo incremento de la función $\Phi(x)$.
- ▶ $-\nabla\Phi(x)$: localmente la dirección de máximo descenso
 $p_k = -\nabla\Phi(x)$.

$$x_{k+1} = x_k - \alpha_k \nabla\Phi(x_k), \quad \nabla\Phi(x_k) = Ax_k - b = r_k$$

$$\Phi(x_{k+1}) = \frac{1}{2} (x_k - \alpha_k r_k)^T A (x_k - \alpha_k r_k) - (x_k - \alpha_k r_k)^T b$$

Método de máximo descenso

Para determinar α_k , minimizamos $\Phi(x_{k+1})$ con respecto de α_k

$$\Phi(x_{k+1}) = \frac{1}{2} (x_k - \alpha_k r_k)^T A (x_k - \alpha_k r_k) - (x_k - \alpha_k r_k)^T b$$

$$\frac{d}{d\alpha_k} \Phi(x_{k+1}) = r_k^T A x_k + \alpha_k r_k^T A r_k - r_k^T b = 0$$

$$\alpha_k = \frac{\nabla \Phi(x_k)^T \nabla \Phi(x_k)}{\nabla \Phi(x_k)^T A \nabla \Phi(x_k)} = \frac{r_k^T r_k}{r_k^T A r_k} = \frac{\langle r_k, r_k \rangle}{\langle r_k, A r_k \rangle}$$

Método de gradiente conjugado

Conjunto de vectores conjugados $\{p_0, p_1, p_2, \dots, p_{n-1}\}$ con respecto a la matriz A

$$p_i^T A p_j = 0 \quad i \neq j$$

forman una base de R^n .

Definimos :

$$x_{k+1} = x_k + \alpha_k p_k$$

$$p_{k+1} = -r_{k+1} + \beta_k p_k, \quad \text{donde } r_k = Ax_k - b$$

- ▶ Se debe determinar α_k y β_k .
- ▶ Se puede demostrar que $r_k^T r_j = 0 \quad \forall k \neq j$

Método de gradiente conjugado

Para determinar α_k se minimiza la función $\Phi(x_{k+1})$

$$\Phi(x_k + 1) = \frac{1}{2} (x_k + \alpha_k p_k)^T (x_k + \alpha_k p_k) - (x_k + \alpha_k p_k)^T b$$

$$\frac{d}{d\alpha_k} \Phi(x_{k+1}) = p_k^T r_k + \alpha_k p_k^T A p_k = 0 \Rightarrow \boxed{\alpha_k = -\frac{p_k^T r_k}{p_k^T A p_k}}$$

usando $p_k = -r_k + \beta_{k-1} p_{k-1}$, tenemos

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k} - \beta_{k-1} \frac{p_{k-1}^T r_k}{p_k^T A p_k}$$

degradando sucesivamente $p_{k-1} \approx r_{k-1}$ y usando la ortogonalidad de los r_k , tenemos

$$\boxed{\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}}$$

Método de gradiente conjugado

Para determinar β_k , utilizamos

$$\begin{aligned} p_k^T A(p_{k+1} &= -r_{k+1} + \beta_k p_k) \quad \text{sabiendo que } p_k^T A p_{k+1} = 0 \\ \beta_k &= \frac{p_k^T A r_{k+1}}{p_k^T A p_k} \end{aligned}$$

utilizando las definiciones de p_k y usando la ortogonalidad de los r_k se puede mostrar que

$$\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

Método de gradiente conjugado

For $k = 0, 1, 2, ..$ until convergence

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = r_k + \alpha_k A p_k$$

$$\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

$$p_{k+1} = -r_{k+1} + \beta_k p_k$$

End

Método de gradiente conjugado

Para $k = 0$ tenemos

$$\begin{aligned}\alpha_0 &= \frac{r_0^T r_0}{p_0^T A p_0} \\ x_1 &= x_0 + \alpha_0 p_0 \\ r_1 &= r_0 + \alpha_0 A p_0 \\ \beta_0 &= \frac{r_1^T r_1}{r_0^T r_0} \\ p_1 &= -r_1 + \beta_0 p_0\end{aligned}$$

- Necesitamos $r_0 = Ax_0 - b$ y p_0 .
- x_0 y p_0 son arbitrarios.
- Tomamos x_0 cualquiera (inclusive cero) y $p_0 = -r_0$.

Estimación del error

Error en la iteración i :

$$\delta_i = |\mathbf{X}^i - \mathbf{X}^{i-1}|, \quad i > 1$$

Criterio de convergencia:

Si $\delta_i < \epsilon \Rightarrow$ detener método

Sistemas mal condicionados

Ref: [Ascher, First Course in Numerical Methods]

Si tenemos un sistema lineal

$$A\mathbf{x} = \mathbf{b},$$

donde \mathbf{x} es la solución exacta y $\hat{\mathbf{x}}$ es la solución aproximada.
Sería deseable calcular, para alguna norma, el error

- ▶ absoluto : $\|\mathbf{x} - \hat{\mathbf{x}}\|$
- ▶ relativo $\|\mathbf{x} - \hat{\mathbf{x}}\|/\|\mathbf{x}\|$

Ningún error se puede calcular, mejor es analizar el residuo

$$\hat{\mathbf{r}} = \mathbf{b} - A\hat{\mathbf{x}}$$

Sistemas mal condicionados

Estimación del error relativo

$$\begin{aligned}\hat{r} &= \mathbf{b} - A\hat{x} = A\mathbf{x} - A\hat{x} = A(\mathbf{x} - \hat{x}) \\ \mathbf{x} - \hat{x} &= A^{-1}\hat{r}\end{aligned}$$

para una norma $\|\cdot\|$ y la correspondiente norma matricial inducida

$$\|\mathbf{x} - \hat{x}\| = \|A^{-1}\hat{r}\| \leq \|A^{-1}\| \|\hat{r}\| \quad \text{error absoluto acotado}$$

por otro lado tenemos $\|\mathbf{b}\| \leq \|A\| \|\mathbf{x}\|$

$$\frac{\|\mathbf{x} - \hat{x}\|}{\|\mathbf{x}\|} \leq \kappa(A) \frac{\|\hat{r}\|}{\|\mathbf{b}\|}$$

donde $\kappa(A) = \|A\| \|A^{-1}\|$ es el número de condicionamiento.

Sistemas mal condicionados

Observaciones

- ▶ $\kappa(A)$ no depende de la norma utilizada.
- ▶ El error relativo está acotado por el valor de $\kappa(A)$ multiplicado por el residuo.
- ▶ $\kappa(A) \approx 1$ se dice que el sistema está bien condicionado.
- ▶ $\kappa(A) \gg 1$ se dice que el sistema está mal condicionado y ningún método encontrará la solución.

Sistemas mal condicionados

Ejemplo

$$A = \begin{bmatrix} 1,2969 & 0,8648 \\ 0,2161 & 0,1441 \end{bmatrix} ; \quad b = \begin{bmatrix} 0,8642 \\ 0,1440 \end{bmatrix}$$
$$\hat{x} = \begin{bmatrix} 0,9911 \\ 0,4870 \end{bmatrix} , \quad \hat{r} = \mathbf{b} - A\hat{x} = \begin{bmatrix} -10^{-8} \\ 10^{-8} \end{bmatrix}$$

considerando la norma infinita $\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$ y sabiendo que

$$\mathbf{x} = \begin{bmatrix} 2 \\ -2 \end{bmatrix} , \text{ entonces } \|\mathbf{x} - \hat{x}\|_{\infty} = 1,513$$

El error absoluto es del mismo orden que la solución \mathbf{x}

Sistemas mal condicionados

$$A^{-1} = 10^8 \begin{bmatrix} 0,1441 & -0,8648 \\ -0,2161 & 1,2969 \end{bmatrix} ; \quad \|A\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$
$$\|A^{-1}\|_{\infty} = 1,513 \times 10^8 , \quad \kappa_{\infty}(A) = 3,27 \times 10^8$$

tenemos que $\kappa_{\infty}(A) \gg 1$, entonces la matriz esta mal condicionada.